



SAĞLIKTA YAPAY ZEKA YARIŞMASI

PROJE DETAY RAPORU

GÖREV: Akciğer Grafileri Üzerinden Yapay Zekâ ile Kardiyomegali (Kalp Büyümesi) Saptanması ve Kardiyotorasik Oranın Otomatik Hesaplanması

Yarışma Eğitim Seviyesi: Lise Seviyesi

Proje Adı: NeuroMed

Takım Adı: ÇGMPL Neuronauts

Takım ID: #724334

Başvuru ID: #3579510

İçindekiler

1. TAKIM ŞEMASI	3
2. PROBLEME EN YAKIN ÇÖZÜM SUNAN ULUSLARARASI MAKALELERİN ÖZETİ ...	3
3. KULLANILAN VERİ SETİ VE ALGORİTMALAR	4
3.1. VERİ SETLERİ	4
3.2. GÖRÜNTÜ ÖN İŞLEME	4
3.2.1. GAMMA DÜZELTİMİ	5
3.2.2. CLAHE	5
3.3. KTO	5
3.3.1. BÖLÜTLEME VERİ SETİ	5
3.3.2. KALP BÖLÜTLEMESİ	6
3.3.3. AKCİĞER BÖLÜTLEMESİ	6
3.4. ÖZNİTELİK TABANLI SINIFLANDIRMA	6
3.4.1. KTO KULLANIMI	6
3.4.2. KALP ALANLARI	7
3.4.3. KALP/AKCİĞER ALAN ORANI	7
3.4.4. CNN SINIFLANDIRICI	7
3.4.5. MAKİNE ÖĞRENMESİ MODELİ	7
4. SONUÇLAR VE İNCELEME	8
4.1. TEST YAPISI VE DEĞERLENDİRME KRİTERLERİ	8
4.2. KTO HESAPLAMA PERFORMANSI	8
4.3. SINIFLANDIRMA SONUÇLARI	8
4.4. AÇIKLANABİLİR YAPAY ZEKA	9
4.5. OTOMATİK HİPERPARAMETRE AYARLAMA	9
4.6. GÜÇLÜKLER VE ÇÖZÜM YOLLARI	9
4.7. GENEL DEĞERLENDİRME	10
5. ÖZGÜNLÜK	10
5.1. SENTETİK VERİ ÜRETİMİ	10
5.2. MODEL ODAK TAKİBİ	10
5.3. AŞIRI ÖĞRENME ENGELLEME	11
5.4. OTOMATİK HİPERPARAMETRE AYARLAMA	11
6. REFERANSLAR	11

1. TAKIM ŞEMASI

Tablo 1 - Takım Şeması

Rol	Deneyim	Görev	Uzmanlık
Kaptan	3 Yıl	Model/Hiperparametre Ayarlama	Tensorflow – PyTorch – Scikit-Learn
Üye	3 Yıl	Veri İşleme – Özellik Mühendisliği	Pandas – NumPy - OpenCV
Üye	1 Yıl	Model/Hiperparametre Ayarlama	Tensorflow – PyTorch – Scikit-Learn
Üye	3 Yıl	Model Optimizasyonu	Tensorflow – Keras – Scikit-Learn
Üye	1 Yıl	Veri İşleme – Veri Görselleştirme	Pandas – NumPy - Matplotlib

2. PROBLEME EN YAKIN ÇÖZÜM SUNAN ULUSLARARASI MAKALELERİN ÖZETİ

Automated Cardiothoracic Ratio Calculation And Cardiomegaly Detection Using Deep Learning Approach [1]: KTO'nun manuel hesaplanması yoruma açık olduğundan, radyolojistler arası farklılıklar klinik tutarlılığı azaltabilmektedir. Bu sorunu aşmak için makalede, VGG16 ve U-Net tabanlı otomatik hesaplama önerilmiş ve %76,5 doğruluk elde edilmiştir. Bu projede ise U-Net++ ve DeepLabV3+ mimarileri kullanılarak benzer bir yöntem uygulanmış; kalp ve akciğer bölütlemeleri doğrultusunda KTO değeri otomatik hesaplanmıştır. Sonuç olarak %7,5 SMAPE değeri elde edilmiş, bu da modelin klinik uyum ve ölçüm güvenilirliği sağladığını göstermiştir.

Generative Adversarial Network Based Synthetic Learning and a Novel Domain Relevant Loss Term for Spine Radiographs [2]: Kardiyomegali gibi düşük görsel çeşitliliğe sahip durumlarda, derin öğrenme modelleri genelleme sorunu yaşayabilir. Bu çalışmada, makalede önerilen StyleGAN2-ADA ile sentetik kardiyomegali görüntüleri üretilmiş ve veri setine entegre edilmiştir. Mimari, veri setinde çeşitlilik sağlayarak modelin F1 skorunu %90,3'ten %91,4'e yükseltmiştir.

Effective processing pipeline PACE 2.0 for enhancing chest x-ray contrast and diagnostic interpretability [3]: Düşük kontrast ve parlaklık dengesizlikleri, sınıflandırma doğruluğunu düşürebilmektedir. Makalede bu sorunlara karşı Gamma düzeltimi ve CLAHE ile görüntü kalitesinin artırıldığı belirtilmiştir. Bu projede de aynı yöntemler ön işlemede kullanılarak F1 skoru %90,5'ten %91,4'e çıkarılmıştır.

Optuna: A Next-generation Hyperparameter Optimization Framework [4]: Hiperparametrelerin manuel ayarlanması model doğruluğunu sınırlayabilir. Makalede, Optuna gibi otomatik arama yöntemlerinin geniş parametre uzaylarında daha verimli sonuçlar sağladığı vurgulanmaktadır. Projede de Optuna kullanılarak en uygun hiperparametreler bulunmuş ve modelin F1 skoru %89,4'ten %91,4'e çıkmıştır.

Explainable Artificial Intelligence in Radiological Cardiovascular Imaging — A Systematic Review [5]: Yapay zekâ modellerinin yorumlanabilir olmaması, kardiyomegali gibi kritik tanılarda güveni zayıflatmaktadır. Makalede önerilen Grad-CAM ve SHAP yöntemleriyle bu çalışmada model kararları görsel ve sayısal olarak analiz edilmiştir. Projede Grad-CAM çıktıları CNN seçiminde kullanılmış; SHAP ile öznitelik katkıları değerlendirilerek sistemin açıklanabilirliği ve güvenilirliği artırılmıştır.

Efficient Object Localization Using Convolutional Networks [6]: Derin öğrenme modelleri, veri çeşitliliği yüksek olsa dahi aşırı öğrenmeye eğilimlidir. Makalede bu soruna karşı önerilen Spatial Dropout yöntemi, projede geliştirilen özgün CNN mimarisine %30 oranında entegre edilmiştir. Elde edilen öznitelikler makine öğrenmesi modeline aktarılmış; bu sayede F1 skoru %89,9'dan %91,4'e çıkarılmıştır.

Radiological Cardiothoracic Ratio in Evidence-Based Medicine [7].

Kardiyomegalide yapısal değişimlerin doğrudan saptanamaması tanıyı zorlaştırır. Makalede, kalp ve toraks alan oranlarının bu soruna çözüm sunduğu belirtilmiştir. Bu çalışmada da bölütleme maskelerinden türetilen öznetelikler, öznetelik tabanlı sınıflandırma modeline eklenerek doğruluk ve açıklanabilirlik artırılmıştır. Böylece modelin F1 skoru %82,2'den %91,4'e çıkarılmıştır.

A convolutional attention mapping deep neural network for classification and localization of cardiomegaly on chest X-rays [8]: Kardiyomegali gibi yapısal hastalıklarda görsel örüntülerin göz ardı edilmesi tanı doğruluğunu düşürebilir. Makaleye göre CNN mimarileri bu örüntüleri etkili biçimde öğrenebilmektedir. Bu projede, geliştirilen CNN modelinin çıktısı öznetelik tabanlı sınıflandırmaya entegre edilerek F1 skoru %88,2'den %91,4'e yükseltilmiştir.

3. KULLANILAN VERİ SETİ VE ALGORİTMALAR

3.1. VERİ SETLERİ


Bu çalışmada, kardiyomegali tanısına yönelik derin öğrenme temelli bir model geliştirmek amacıyla, coğrafi, kurumsal ve teknolojik çeşitlilik gösteren beş yaygın göğüs radyografi veri seti kullanılmıştır. Bu çeşitlilik, modelin farklı hasta gruplarına genellenebilirliğini artırmayı hedeflemektedir. Veri setleri eğitim ve test için dengeli şekilde yapılandırılmış; yalnızca açık erişimli veya başvuruya ulaşılabilen, etik ilkelere uygun kaynaklar tercih edilmiştir.

Modelin güvenilirliğini artırmak amacıyla, yalnızca frontal pozisyonda ve PA (posterior-anterior) projeksiyonla elde edilen görüntüler dahil edilmiş; lateral ve AP çekimler dışlanmıştır. PA çekimler, kalp boyutunun doğru ölçümü ve mediastinal yapıların sağlıklı değerlendirilmesi açısından klinik olarak en uygun yöntemdir [9].

Kardiyomegali tanılı görüntüler, sınıf dengesi sağlamak amacıyla rastgele seçilen negatif örneklerle eşleştirilmiştir. Negatif sınıf yalnızca sağlıklı bireyleri değil, kardiyomegali dışı patolojileri de içerecek şekilde oluşturulmuştur. Böylece model, kardiyomegaliyi hem sağlıklı hem de farklı hastalıklara sahip bireylerden ayırt edebilmektedir.

3.2. GÖRÜNTÜ ÖN İŞLEME

Tıbbi görüntüler, hasta pozisyonu, cihaz ayarları ve ışık koşullarındaki değişkenlikler nedeniyle kontrast düşüklüğü ve parlaklık sorunları içerebilir, bu da yapay zeka analizlerinin doğruluğunu azaltır. Projede, bu sorunları gidermek için Gamma düzeltimi ve CLAHE ön işleme teknikleri kullanılmıştır. Gamma düzeltimi detayları belirginleştirirken CLAHE ise lokal kontrastı iyileştirerek kalp ve çevresinin



Şekil 1 - Veri Seti Dağılımı


Tablo 2 - Veri Seti Dağılımı

Veri Seti	Kullanılan Görüntü Sayısı	Yıl	Erişim	Kaynak Kurum	Grup
PadChest [10]	16.162	2019	Açık	Hospital San Juan - İspanya	Eğitim
MIMIC-CXR [11]	10.000	2019	Etik Onay	Massachusetts Institute of Technology - ABD	Eğitim
CheXpert [12]	5.740	2019	Açık	Stanford University - ABD	Eğitim
VinDr-CXR [13]	4.600	2020	Açık	VinBigData Vietnam	Eğitim
Chest X-Ray 14 [14]	3.000	2017	Açık	NIH Clinical Center - ABD	Test

netleşmesini sağlamıştır. Bu ön işlemler, veri kalitesini artırıp F1 skorunu %90,5'ten %91,4'e çıkarmıştır.

3.2.1. GAMMA DÜZELTİMİ

Radyografilerde kontrast düşüklüğü, kalp sınırlarının silikleşmesi, bölütleme hatalarına neden olabilmektedir. Bu sorunu çözmek amacıyla kullanılan Gamma Düzeltimi [6], parlaklık dağılımını doğrusal olmayan biçimde yeniden ölçeklendirerek düşük kontrastlı alanları belirginleştirir. Bu projede Gamma değeri 3.0 olarak uygulanmış, özellikle kalp konturları netleştirilmiştir. Sonuç olarak F1 skoru %89,9'dan %91,4'e yükselmiştir.



Şekil 2 - Gamma Düzeltimi Karşılaştırması

3.2.2. CLAHE


Kalp çevresindeki dokuların radyografilerde düşük kontrastla temsil edilmesi, bölütleme modelinin sınırları doğru ayırt etmesini zorlaştırır. Literatürde bu sorunu gidermek amacıyla kullanılan CLAHE [6], lokal kontrastı artırarak yapısal detayların belirginliğini yükseltir. Bu projede 2.0 eşik değeriyle uygulanan CLAHE, konturların daha net algılanmasını sağlamış ve F1 skorunu %89,1'den %91,4'e çıkarmıştır.



Şekil 3 - Gamma Düzeltimi Karşılaştırması

3.3. KTO

Kardiyomegali gibi yapısal kalp hastalıklarında görsel yorumlara dayalı tanımlar hekime bağlı farklılık gösterebilir ve erken evrelerde atlanabilir. Bu nedenle objektif ölçütler kritik öneme sahiptir. Literatürde, kalp genişliğinin toraks iç genişliğine oranı olan KTO'nun %50'nin üzerinde olması kardiyomegali göstergesi sayılmakta ve klinikte sıkça kullanılmaktadır. Bu çalışmada KTO, bölütleme ve kenar tespiti temelli bir algoritmayla hesaplanmıştır. Kalp ve akciğerler sırasıyla U-Net++ ve DeepLabV3+ modelleri ile bölütlenmiş; ardından her bir maskeye Canny kenar tespiti uygulanmıştır. Elde edilen kenarlar üzerinden yatay sınırlar belirlenmiş, kalp ve toraks genişlikleri ölçülerek aralarındaki oran KTO olarak hesaplanmıştır. Bu işlem kto() fonksiyonu ile otomatikleştirilmiş, temelinde yer alan distance() fonksiyonu ile en sol ve sağ kenar pikselleri arasındaki yatay mesafe ölçülmüştür. Böylece kalp ve akciğer genişliklerine dayalı KTO değeri güvenilir şekilde elde edilmiştir.



Şekil 4 - KTO

3.3.1. BÖLÜTLEME VERİ SETİ

Kalp ve akciğer bölütleme modellerinin eğitimi için, 2025 yılında yayımlanan ve PhysioNet üzerinden erişilebilen CheXmask adlı güncel veri seti kullanılmıştır. Bu veri seti, çeşitli akciğer hastalıklarını içeren geniş bir popülasyona ait 657.566 adet maske sunmakta ve kalp ile akciğer yapılarını piksel düzeyinde etiketlemektedir. Ancak hesaplama kısıtları nedeniyle çalışmada yalnızca 30.000 görüntü seçilerek eğitimde kullanılmıştır. Veri aktarım verimliliği amacıyla maskeler


Tablo 3 - CheXmask Veri Seti

Veri Seti Adı	CheXmask
Yayın Yılı	2025
Kaynak	PhysioNet
Maske Sayısı	657.566
Projedeki Maske Sayısı	30.000
Sıkıştırma Yöntemi	RLE
Erişim	Açık Veri

Run-Length Encoding yöntemiyle sıkıştırılmıştır. CheXmask'in açık erişimli yapısı, derin öğrenme temelli tıbbi görüntüleme projeleri için güçlü bir kaynak sağlamaktadır.

3.3.2. KALP BÖLÜTLEMESİ


KTO hesaplamasında kalbin doğru bölütlenmemesi oran üzerinde ciddi hatalara yol açabilir. Bu nedenle, literatürde detay koruyucu atlama bağlantılarına sahip U-Net++ [16] modeli önerilmektedir. Projede, kalp bölütlemesi için kullanılan U-Net++ mimarisi, 256x256 boyutlu girişler ve yaklaşık 8 milyon parametreyle eğitilmiş; %87,26 IoU skoru ile yüksek doğruluk elde edilmiştir. Modelin kodlayıcı-çözücü yapısı ve her blokta uygulanan Batch Normalization ve Dropout katmanları, öğrenme stabilitesini ve genellenebilirliği artırmıştır.



Şekil 5 - U-Net++ Mimarisi

3.3.3. AKCİĞER BÖLÜTLEMESİ


Akciğer sınırlarının hatalı belirlenmesi, KTO'nun doğruluğunu doğrudan etkiler. Literatürde bu soruna çözüm olarak çok ölçekli yapıları tanıyabilen DeepLabV3+ modeli önerilmektedir. Bu projede de omurga ağı olarak ResNet101 kullanılan ve genişlemeli evrişim ile çoklu bağlamsal bilgi çıkarımı sağlayan ASPP modülüne sahip DeepLabV3+ mimarisi ile akciğer bölütlemesi gerçekleştirilmiştir. Modelin genişletilmiş evrişim ve yeniden boyutlandırma katmanları sayesinde akciğerin genel yapısı ve sınır detayları başarılı şekilde yakalanmıştır. Eğitimde kullanılan 256x256 boyutundaki görüntülerle model, sağ akciğer için 0.9111, sol akciğer için 0.8953 IoU skorlarına ulaşarak yüksek doğruluk göstermiştir.



Şekil 6 - DeepLabV3+ Mimarisi

3.4. ÖZNİTELİK TABANLI SINIFLANDIRMA

Kardiyomegali gibi yapısal hastalıkların tanısında yalnızca görüntü temelli yaklaşımlar, modelin açıklanabilirliğini ve klinik güvenilirliğini sınırlayabilmektedir. Bu nedenle çalışmada, hem anatomik hem de derin öğrenme temelli bilgileri içeren çok boyutlu ve yorumlanabilir bir yöntem benimsenmiştir. Bu kapsamda, modelde beş öznelik birleştirilmiştir: kalp ve akciğer genişliklerinden hesaplanan KTO, sağ ve sol kalp alanları, kalp/akciğer alan oranı ve CNN tabanlı sınıflandırıcıdan elde edilen kardiyomegali olasılığı. Elde edilen hibrit öznelik vektörü, farklı algoritmalarla test edilmiş ve en yüksek başarı LightGBM makine öğrenimi algoritmasıyla sağlanmıştır. Sonuç olarak, model %91,4 F1 skoru ile yüksek doğruluk ve dengeli performans sergilemiştir.



Şekil 7 - Kardiyomegali Tespiti Akış Şeması


3.4.1. KTO KULLANIMI

Kardiyomegalinin yalnızca görüntü sınıflandırmasına dayalı olarak tespit edilmesi, özellikle erken evrelerde yapısal değişimlerin atlanmasına neden olabilir. Bu nedenle literatürde, kalp genişliğinin toraks genişliğine oranı olan KTO, sayısal ve objektif bir

tanısal ölçüt olarak sıkça önerilmektedir. Bu çalışmada KTO, “3.3. KTO” başlığında detaylandırılan bölütleme tabanlı algoritma ile otomatik olarak hesaplanmış ve makine öğrenmesi modeline doğrudan bir öznitelik olarak dahil edilmiştir. Yapısal bilgi içeren bu oran, modelin kararlarını şekillendirmede önemli rol oynamış ve kardiyomegali tespitinde doğruluk düzeyini artırmıştır.

3.4.2. KALP ALANLARI


Kardiyomegalide kalbin genellikle sola doğru genişlemesi, tanısal açıdan önemli bir anatomik bulgu olarak değerlendirilir. Literatürde bu asimetrik genişlemenin tanısal önemi vurgulanmaktadır. Bu çalışmada, büyüme yönünü sayısal analiz edebilmek için sağ ve sol akciğer maskelerinin en yakın uçlarından orta hat belirlenmiş, kalp maskesi bu hatta göre ikiye bölünerek sağ ve sol kalp alanları öznitelik olarak sınıflandırma modeline eklenmiştir. Böylece model, kardiyomegalinin yönelimsel örüntülerini daha doğru şekilde öğrenmiştir.



Şekil 8 - Kalp Alanları

3.4.3. KALP/AKCIĞER ALAN ORANI


Kalbin genişlemesine bağlı olarak akciğer hacminin azalması, kardiyomegali tanısında önemli bir etkidir. Literatürde bu ilişkinin kalp-akciğer alan oranıyla sayısal olarak ifade edilebileceği belirtilmektedir. Bu çalışmada, U-Net++ ile kalp, DeepLabV3+ ile akciğer bölütlemesi yapılmış; sağ ve sol akciğer alanları birleştirilerek kalp alanıyla oranlanmıştır. Elde edilen oran, sınıflandırma modeline öznitelik olarak eklenmiş ve karar sürecine katkı sağlamıştır.



Şekil 9 - Kalp/Akciğer Alan Oranı

3.4.4. CNN SINIFLANDIRICI

Kardiyomegali tanısının yalnızca sayısal verilere dayanarak yapılması görsel örüntülerin göz ardı edilmesine sebep olmaktadır. Literatürde, derin öğrenme modellerinin bu tür örüntüleri öğrenerek tanı başarısını artırdığı belirtilmiştir [8]. Bu projede geliştirilen model, 256x256 boyutundaki radyografi görüntülerinden sigmoid aktivasyon fonksiyonu ile kardiyomegali olasılık skoru üretmiş; artık bağlantılar ve dikkat odaklı yapılarla anlamlı görsel öznitelikler etkili şekilde öğrenilmiştir. Yaklaşık 3 milyon parametre içeren yapıya Spatial Dropout ve L2 düzenleştirmesi entegre edilerek F1 skoru %88,2’den %91,4’e yükseltilmiştir.



Şekil 10 - Geliştirilen CNN Mimarisi

3.4.5. MAKİNE ÖĞRENMESİ MODELİ

Kardiyomegali tanısında yalnızca görüntüye dayalı kararlar yetersiz kalabilir. Literatürde KTO ve kalp/akciğer oranı gibi yapısal ölçütlerin tanısal değeri vurgulanmaktadır [1]. Bu çalışmada, söz konusu öznitelikler ile CNN tabanlı kardiyomegali olasılık skoru birleştirilerek hibrit öznitelik vektörü oluşturulmuştur. 5 farklı makine öğrenmesi algoritması ve 2 toplu öğrenme yöntemi ile test edilmiştir. Tablo 4’te gösterildiği üzere en yüksek başarıyı

Tablo 4 - Skor Tablosu

Model	F1 Skoru
LightGBM	%91,40
XGBoost	%90,96
Voting	%90,42
MLP	%89,33
RandomForest	%89,23
SVC	%88,99
Stacking	%86,67

%91,4 F1 skoru ile LightGBM sağlamıştır. Böylece hem yapısal hem görsel veriyeye dayanan, açıklanabilir ve yüksek doğrulukta bir sistem geliştirilmiştir.


4. SONUÇLAR VE İNCELEME

4.1. TEST YAPISI VE DEĞERLENDİRME KRİTERLERİ

Geliştirilen modelin test süreci, NIH tarafından yayımlanan ve gerçek klinik ortamlardan toplanmış 112.120 PA akciğer radyografisini içeren ChestX-ray14 veri seti üzerinden yürütülmüştür. Test aşamasında, pozitif ve negatif örneklerden dengeli biçimde seçilen toplam 3.000 görüntüden oluşan (1500 pozitif / 1500 negatif) bir alt küme kullanılmıştır. Bu alt küme, eğitim verisine dahil edilmeyerek modelin yeni verilere karşı genellenebilirliğini değerlendirmek amacıyla ayrılmıştır. Değerlendirme ölçütü olarak F1 skoru ve ROC eğrisi altında kalan alan (AUC) esas alınmıştır. Test sonuçlarına göre, geliştirilen öznelik tabanlı sınıflandırma modeli %91.4 F1 skoru ve %96 AUC değeri ile yüksek doğruluk ve güvenilirlik göstermiş; klinik karar destek sistemleri için etkili bir çözüm sunduğunu ortaya koymuştur.

4.2. KTO HESAPLAMA PERFORMANSI


Projede geliştirilen KTO hesaplama sistemi, TEKNOFEST yarışma komitesince sağlanan ve FTP üzerinden temin edilen, KTO değerlerini içeren 102 görüntülük özel veri seti üzerinde test edilmiştir. Yapılan değerlendirmeler sonucunda %7,5 SMAPE, %7,3 MAPE ve 0,42 MAE gibi düşük hata oranları elde edilmiş; bu da sistemin klinik doğruluk ve güvenilirliğini ortaya koymuştur. Gerçek ve tahmin edilen KTO değerleri Şekil 11'de karşılaştırmalı olarak sunulmuştur. Bu başarının temelinde, anatomik yapıları doğru şekilde tespit eden bölütleme aşaması önemli rol oynamıştır. Kalp için kullanılan U-Net++ modeli %87,26 IoU, akciğer bölütlemesinde kullanılan DeepLabV3+ ise sağ akciğer için %91,11 ve sol akciğer için %89,53 IoU skoru ile yüksek doğruluk sunmuştur. Bu sonuçlar, KTO hesaplamasının anatomik temelli ve güvenilir şekilde yapıldığını güçlü bir şekilde desteklemektedir.




Şekil 11 - KTO Karşılaştırması

4.3. SINIFLANDIRMA SONUÇLARI

Projede geliştirilen öznelik tabanlı sınıflandırma modeli, ChestX-ray14 veri setinden seçilen dengeli 3.000 görüntü (1.500 pozitif / 1.500 negatif) üzerinde test edilmiştir. %91,4 F1 skoru ve %96 AUC değeriyle modelin yüksek sınıflandırma performansı doğrulanmıştır. ROC eğrisi ve karışıklık matrisi analizleri, sınıflandırıcının güçlü ayırt etme yetisini ortaya koymuştur. Şekil 14'te yer alan grafik incelendiğinde, CNN mimarisi ilk birkaç epokta öğrenme sürecine hızlı bir şekilde adapte olmuş, eğitim doğruluğunda belirgin bir artış göstermiştir. Şekil 15'te verilen performans grafiklerine göre sağ akciğer bölütlemesinde DeepLabV3+ mimarisi,




Şekil 12 - ROC Eğrisi Şekil 13 - Karışıklık Matrisi



Şekil 14 - CNN Modeli Performans Grafiği


eğitim sürecinde hızlı ve istikrarlı bir şekilde yüksek doğruluğa ulaşmıştır. Sol akciğer bölütlemesinde de aynı mimari kullanılmış; model belirli epoklardan sonra dengeli bir doğrulama eğrisi göstermiştir. Kalp bölütlemesinde kullanılan U-Net++ modeli ise kısa sürede yüksek doğruluğa ulaşarak doğrulama başarısını kararlı biçimde sürdürmüştür. Elde edilen bu güçlü performans, modelin klinik karar destek sistemlerinde kullanılabilir, güvenilir ve genellenebilir bir yapıya sahip olduğunu göstermektedir.



Şekil 15 - Bölütleme Modelleri Performans Grafikleri

4.4. AÇIKLANABİLİR YAPAY ZEKA

Derin öğrenme modellerinin karar süreçlerinin yorumlanamaması, klinik uygulamalarda güven sorununa yol açmaktadır. Bu çalışmada, modelin hangi özniteliklere dayanarak karar verdiğini açıklamak amacıyla SHAP analizi uygulanmıştır. SHAP, her öznenin modele katkısını birbirinden bağımsız hesaplayarak açıklanabilirlik sunar. Analiz sonucunda en etkili değişkenlerin sırasıyla CNN çıktısı (0.012), kalp-akciğer oranı (0.009), KTO (0.006), sağ kalp oranı (0.004) ve sol kalp oranı (0.003) olduğu belirlenmiştir. Bu bulgular, modelin hem görsel hem de yapısal bilgilere dayalı karar verdiğini ve kararlarının klinik açıdan izlenebilir olduğunu göstermektedir. Bu sayede modelin kararları anlaşılır hale gelmiş, klinik güvenilirliği artmıştır.



Şekil 16 - SHAP Analizi

4.5. OTOMATİK HİPERPARAMETRE AYARLAMA

Öznitelik tabanlı sınıflandırma modellerinde hiperparametrelerin manuel ayarlanması, zaman alıcı olmakla birlikte model başarısını sınırlayabilmektedir. Bu çalışmada, sınıflandırma aşamasında kullanılan 5 farklı makine öğrenmesi algoritması Optuna ile ayrı ayrı optimize edilmiştir. Her bir algoritma için öğrenme oranı, ağaç derinliği ve tahminleyici sayısı gibi kritik parametrelerde 150'şer deneme yapılmış ve elde edilen en iyi sonuçlarla modeller yeniden eğitilmiştir. Karşılaştırmalar sonucunda en yüksek F1 skorunu veren LightGBM sınıflandırıcı olarak seçilmiştir. Bu optimizasyon süreci sayesinde modelin F1 skoru %89,4'ten %91,4'e yükselmiş; doğruluk ve genellenebilirlik anlamında önemli bir iyileşme sağlanmıştır.

4.6. GÜÇLÜKLER VE ÇÖZÜM YOLLARI

Kardiyomegali tanısında yalnızca görüntü temelli sınıflandırma, sınırlı varyasyon ve sınıf belirsizliği nedeniyle yetersiz kalmaktadır. Bu sorunu aşmak için, projede KTO, kalp-akciğer oranı ve CNN çıktılarından oluşan hibrit bir öznitelik yapısı geliştirilmiş ve modelin F1 skoru %91,4 olarak hesaplanmıştır. Aşırı öğrenmeyi önlemek amacıyla CNN modülüne %30 Spatial Dropout uygulanmış; bu sayede modelin F1 skoru %89,9'dan %91,4'e çıkmıştır. Eğitim setine çeşitlilik kazandırmak için StyleGAN2-ADA ile sentetik veri üretilmiş böylece skor %90,3'ten %91,4'e ulaşmıştır. Son aşamada

Optuna ile hiperparametre optimizasyonu gerçekleştirilerek model nihai hâline getirilmiştir. Bu stratejiler bir arada uygulandığında, modelin hem doğruluğu hem de klinik güvenilirliği belirgin biçimde artmıştır.


4.7. GENEL DEĞERLENDİRME

Projede geliştirilen öznitelik tabanlı sınıflandırma yöntemi, kardiyomegali tanısında %91,4 F1 skoru ile yüksek ve dengeli performans göstermiştir. Bu başarı, yalnızca doğruluğu değil, pozitif ve negatif sınıflar arasında sağlanan dengeyi de yansıtmaktadır. Modelin başarısında, U-Net++ ve DeepLabV3+ ile elde edilen hassas bölütleme çıktıları kritik rol oynamıştır. Kalp ve toraks sınırlarının doğru belirlenmesi sayesinde KTO, kalp-akciğer oranı ve bölgesel kalp oranı gibi yapısal öznitelikler güvenilir biçimde hesaplanmıştır. Bölütleme yüksek IoU skorları, öznitelik mühendisliğine sağlam bir temel sağlayarak modelin genellenebilirliğini artırmıştır. Ayrıca, modelin karar süreci SHAP ve Grad-CAM ile açıklanmış; bu sayede önemli öznitelikler net biçimde belirlenmiş ve model çıktıları klinik olarak yorumlanabilir hâle getirilmiştir. Bu açıklanabilirlik, hem kullanıcı güvenini artırmakta hem de sistemin klinik entegrasyonunu kolaylaştırmaktadır. Sonuç olarak, bölütleme destekli öznitelik çıkarımı ile makine öğrenmesi tabanlı sınıflandırmanın birleştiği bu hibrit yapı doğruluk, açıklanabilirlik ve klinik geçerlilik açısından güçlü bir çözüm sunmuştur.

5. ÖZGÜNLÜK

5.1. SENTETİK VERİ ÜRETİMİ

Düşük varyasyonlu kardiyomegali vakası içeren görüntüleme verileri, derin öğrenme modellerinin bu sınıfa özgü örüntüleri yeterince öğrenmesini zorlaştırmakta ve genelleme başarısını sınırlandırmaktadır. Klasik GAN mimarilerinden farklı olarak, StyleGAN2-ADA'nın ADA (Adaptive Discriminator Augmentation) mekanizması sayesinde, sınırlı veriyle dahi kararlı eğitim sağlanmakta ve çeşitli, yüksek kaliteli sentetik örnekler üretilebilmektedir. Bu çalışmada, kardiyomegali sınıfına ait



Şekil 17 – Style GAN2-ADA Mimarisi

radyolojik görüntülerin çeşitliliğini artırmak amacıyla StyleGAN2-ADA ile sentetik göğüs radyografileri üretilmiştir. Görsellerin gerçekliğe yakınlığı, yalnızca piksel benzerliği ile değil, aynı zamanda Fréchet Inception Distance (FID) [18] ile de değerlendirilmiştir. FID, sentetik verilerin gerçek veri dağılımına benzerliğini ölçen bir metrik olup, bu projede pozitif sınıf için 25; negatif sınıf için 21 olarak hesaplanmıştır. Literatürde 10–30 arası FID değeri yüksek kaliteli üretim olarak kabul edildiğinden, bu sonuçlar üretici ağın başarısını doğrulamaktadır. Sentetik görüntülerin eğitime dahil edilmesiyle, F1 skoru %90,3'ten %91,4'e yükselmiştir. Böylece, özellikle az çeşitli sınıflarda üretici ağ destekli çeşitlilik artırımı, sınıflandırma başarısını iyileştirmiştir.

5.2. MODEL ODAK TAKİBİ

Tıbbi yapay zekâ modellerinde yorumlanabilirlik eksikliği, klinik güveni sınırlandıran temel sorunlardandır. Bu nedenle sınıflandırma sisteminde önce InceptionV3 modeli üzerinde Grad-CAM uygulanmış; ancak odaklanan bölgelerin




Şekil 18 – Geliştirilen CNN Modelinden GradCam Örneği

kardiyomegaliyle uyumsuz olduğu görülmüştür. Ardından, projeye özgü geliştirilen CNN mimarisi tercih edilmiş ve Grad-CAM ile modelin kalp çevresi ve torasik yapılara odaklandığı gösterilmiştir. F1 skorunun %2 daha düşük olması da InceptionV3 modelinin yetersizliğini doğrulamıştır. Böylece hem klinik anlamlılık sağlanmış hem de eğitim sürecinde hatalı örüntüler ayıklanarak başarı artırılmıştır.

5.3. AŞIRI ÖĞRENME ENGELLEME


Aşırı öğrenme, karmaşık yapıları derin öğrenme modellerinde, eğitim verisine aşırı uyum sağlayarak genelleme performansını düşürür. Çalışmada bu sorunu azaltmak için klasik Dropout'tan farklı olarak tüm CNN filtrelerini eşzamanlı devre dışı bırakan Spatial Dropout kullanılmıştır. Bu projede, CNN modülüne %30 oranında Spatial Dropout entegre edilmiştir. Böylece daha sağlam görsel öznelikler elde edilmiştir. Bu öznelikler yapısal verilerle birleştirilerek LightGBM ile sınıflandırılmış ve F1 skoru %89,9'dan %91,4'e yükselmiştir.



Şekil 19 - Spatial Dropout Karşılaştırması

5.4. OTOMATİK HİPERPARAMETRE AYARLAMA

Manuel hiperparametre ayarlamaları zaman alıcıdır, dar arama alanları nedeniyle model başarısını sınırlayabilir ve tekrarlanabilirliği azaltabilir. Bu soruna karşı Bayes optimizasyonuna dayalı arama yöntemlerinin, klasik ızgara ve rastgele aramaya kıyasla daha verimli ve isabetli sonuçlar sunduğu görülmüştür. Bu çalışmada, hiperparametre optimizasyon süreci için Optuna tercih edilmiştir. Öğrenme oranı, katman sayısı ve Dropout oranı gibi parametreler, her biri 150 denemelik aramalarla optimize edilmiştir. En yüksek F1 skoru LightGBM modeliyle elde edilmiştir. Bu özgün optimizasyon süreci sonunda öznelik tabanlı sınıflandırma modelinin performansı %89,4'ten %91,4'e yükseltilmiştir.



Şekil 20 - Optuna Akış Şeması

6. REFERANSLAR

- [1] Chamveha, I., Promwiset, T., Tongdee, T., Saiviroonporn, P., & Chaisangmongkon, W. (2020). Automated cardiothoracic ratio calculation and cardiomegaly detection using deep learning approach. arXiv. <https://doi.org/10.48550/arXiv.2002.07468>
- [2] Schonfeld, E., & Veeravagu, A. (2022). Generative Adversarial Network Based Synthetic Learning and a Novel Domain Relevant Loss Term for Spine Radiographs. arXiv [Eess.IV]. Retrieved from <http://arxiv.org/abs/2205.02843>
- [3] Siracusano, G., La Corte, A., Nucera, A.G. et al. Effective processing pipeline PACE 2.0 for enhancing chest x-ray contrast and diagnostic interpretability. Sci Rep 13, 22471 (2023). <https://doi.org/10.1038/s41598-023-49534-y>
- [4] Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A Next-generation Hyperparameter Optimization Framework. arXiv: Learning. <http://export.arxiv.org/pdf/1907.10902>
- [5] Haupt, M., Maurer, M. H., & Thomas, R. P. (2025). Explainable Artificial Intelligence in Radiological Cardiovascular Imaging-A Systematic Review. *Diagnostics (Basel, Switzerland)*, 15(11), 1399. <https://doi.org/10.3390/diagnostics15111399>

- [6] Bregler, C. (2015). Efficient object localization using Convolutional Networks. 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). <https://doi.org/10.1109/CVPR.2015.7298664>
- [7] Truszkiewicz, K., Poręba, R., & Gać, P. (2021). Radiological Cardiothoracic Ratio in Evidence-Based Medicine. *Journal of clinical medicine*, 10(9), 2016. <https://doi.org/10.3390/jcm10092016>
- [8] Innat, M., Hossain, M. F., Mader, K., & Kouzani, A. Z. (2023). A convolutional attention mapping deep neural network for classification and localization of cardiomegaly on chest X-rays. *Scientific reports*, 13(1), 6247. <https://doi.org/10.1038/s41598-023-32611-7>
- [9] Kumrular, R. K. & Polat, A. (2021). Klinik Uygulamalarda İleri Biyomedikal Görüntüleme Teknolojileri. *Avrupa Bilim ve Teknoloji Dergisi*, (23), 209-211.
- [10] Bustos, A., Pertusa, A., Salinas, J.-M., & de la Iglesia-Vayá, M. (2020). PadChest: A large chest x-ray image dataset with multi-label annotated reports. *Medical Image Analysis*, 66, 101797. <https://doi.org/10.1016/j.media.2020.101797>
- [11] Johnson, A., Pollard, T., Mark, R., Berkowitz, S., & Horng, S. (2024). MIMIC-CXR Database (version 2.1.0). PhysioNet. RRID:SCR_007345. <https://doi.org/10.13026/4iqj-jw95>
- [12] Irvin, J., Rajpurkar, P., Ko, M., Yu, Y., Ciurea-Illcus, S., Chute, C., ... Ng, A. Y. (2019). CheXpert: A Large Chest Radiograph Dataset with Uncertainty Labels and Expert Comparison. arXiv [Cs.CV]. Retrieved from <http://arxiv.org/abs/1901.07031>
- [13] Nguyen, H.Q., Lam, K., Le, L.T. et al. VinDr-CXR: An open dataset of chest X-rays with radiologist's annotations. *Sci Data* 9, 429 (2022). <https://doi.org/10.1038/s41597-022-01498-w>
- [14] Wang, X., Peng, Y., Lu, L., Lu, Z., Bagheri, M., & Summers, R. M. (2017). ChestX-ray8: Hospital-scale chest X-ray database and benchmarks on weakly-supervised classification and localization of common thorax diseases. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 3462–3471). IEEE. <https://doi.org/10.1109/CVPR.2017.369>
- [15] Gaggion, N., Mosquera, C., Mansilla, L. et al. CheXmask: a large-scale dataset of anatomical segmentation masks for multi-center chest x-ray images. *Sci Data* 11, 511 (2024). <https://doi.org/10.1038/s41597-024-03358-1>
- [16] Neha, F., Bhati, D., Shukla, D. K., Dalvi, S. M., Mantzou, N., & Shubbar, S. (2024). U-Net in Medical Image Segmentation: A Review of Its Applications Across Modalities. arXiv [Eess.IV]. Retrieved from <http://arxiv.org/abs/2412.02242>
- [17] Murugappan, M., Bourisly, A.K., Prakash, N.B. et al. Automated semantic lung segmentation in chest CT images using deep neural network. *Neural Comput & Applic* 35, 15343–15364 (2023). <https://doi.org/10.1007/s00521-023-08407-1>
- [18] Segal, B., Rubin, D. M., Rubin, G., & Pantanowitz, A. (2021). Evaluating the Clinical Realism of Synthetic Chest X-Rays Generated Using Progressively Growing GANs. *SN computer science*, 2(4), 321. <https://doi.org/10.1007/s42979-021-00720-7>