



SAĞLIKTA YAPAY ZEKA YARIŞMASI

PROJE SUNUŞ RAPORU

GÖREV: Kolonoskopi Görüntülerinden Polip Segmentasyonu

Yarışma Eğitim Seviyesi: Lise Seviyesi

Proje Adı: NeuroMed

Takım Adı: ÇGMPL Neuronauts

Takım ID: #724334

Başvuru ID: #3579510

İçindekiler Tablosu

1. TAKIM ŞEMASI.....	3
2. PROBLEME EN YAKIN ÇÖZÜM SUNAN ULUSLARARASI MAKALELERİN ÖZETİ	3
3. KULLANILAN VERİ SETİ VE ALGORİTMALAR	4
3.1. SUNUCU VE SQL.....	4
3.1.1. SQLITE VERİ İŞLEME.....	4
3.1.2. BASE64 ŞİFRELEME ALGORİTMASI	4
3.1.3. RLE SIKIŞTIRMA ALGORİTMASI	4
3.2. VERİ SETLERİMİZ	5
3.3. VERİ ÖN İŞLEME	5
3.3.1. SQLITE VERİ AKTARMA	5
3.3.2. GAUSSIAN BULANIKLAŞTIRMA	6
3.3.3. HİSTOGRAM EŞİTLEME.....	6
4. SONUÇLAR VE İNCELEME	6
4.1. ATTENTION U-NET / GELİŞMİŞ ATTENTION U-NET.....	7
4.2. U-NET++	7
4.3. DEEPLABV3+.....	7
4.4. PVT-CASCADE	8
4.5. PATCH REFINEMENT NETWORK	8
4.6. SONUÇLAR.....	8
5. ÖZGÜNLÜK.....	9
5.1. BİLATERAL FİLTRELEME.....	9
5.2. ELASTİK DEFORMASYON	10
5.3. KOMBİNASYON FONKSİYONU	10
5.4. GÖRÜNTÜ VERİ ÜRETİCİSİ.....	10
5.5. CAWR ALGORİTMASI	10
6. REFERANSLAR	10

1. TAKIM ŞEMASI

Kaptan	Model Geliştirme – Matematik
Üye	Veri İşleme – Görüntü İşleme
Üye	Model / Veri - Matematik
Üye	Model Geliştirme
Üye	Veri İşleme

Tablo 1 - Takım Şeması

2. PROBLEME EN YAKIN ÇÖZÜM SUNAN ULUSLARARASI MAKALELERİN ÖZETİ

Enhancing Colonoscopy Image Quality Through Multi-Step Computational Pre-Processing Techniques [1]: Makalede, kolonoskopi görüntü kalitesini artırmak için çok aşamalı ön işleme uygulanmıştır. Kontrast iyileştirme için histogram eşitleme ve CLAHE, gürültü azaltımı için Gaussian Blur ve filtreleme teknikleri kullanılmıştır.

Impact of Image Preprocessing Methods on Polyp Localization in Colonoscopy Frames [2]: Speküler yansımalar, medyan farkı ile tespit edilip içboyama (inpainting) yöntemi ile düzeltilmiştir. Siyah maske, vadilerdeki etkiyi azaltarak polip sınırlarını korur. Kan damarları, uygun renk kanalı kullanılarak zayıflatılmış ve böylece polip segmentasyonu netleştirilmiştir.

Elastic Deformations for Data Augmentation in Breast Cancer Mass Detection [3]: Makale, mamogram görüntülerinde veri çoğaltma için elastik deformasyon tekniklerini tanıtmaktadır. Bu yöntem, meme dokusunun röntgen görüntülerindeki gerilmesini taklit ederek kitlenin tespit başarısını artırmaktadır. Projede polip görüntülerinin çoğaltılmasında kullanılmış ve halka açık veri setleriyle doğrulanmıştır.

Polyp Segmentation in Colonoscopy Images Using Fully Convolutional Network [4]: Makalede, kolonoskopi görüntülerinde polip segmentasyonu için Tam Evrişimli Ağlar (Fully Convolutional Networks - FCN) kullanılmıştır. CVC-ColonDB veri seti üzerinde yapılan değerlendirmelerde, önerilen yöntem önceki segmentasyon yöntemlerine kıyasla daha yüksek doğruluk elde edilmiştir.

Real-Time Polyp Detection, Localization and Segmentation in Colonoscopy Using Deep Learning [5]: Bu çalışma, kolonoskopide polip tespiti, lokalizasyonu ve segmentasyonu için derin öğrenme tabanlı yöntemleri değerlendirmektedir. Kvasir-SEG veri setiyle karşılaştırılan yöntemler arasında ColonSegNet, tespitte 0.80 hassasiyet, 0.81 IoU, segmentasyonda 0.82 dice katsayısı ve 182.38 kare/saniye hız ile en iyi performansı göstermiştir.

Focus U-Net: A novel dual attention-gated CNN for polyp segmentation during colonoscopy [6]: Makalede kolonoskopi polip segmentasyonu için uzamsal ve kanal tabanlı dikkat mekanizmalarını birleştiren Focus U-Net modelini geliştirilmiştir. CVC-ClinicDB ve Kvasir-SEG veri setlerinde sırasıyla 0.941 ve 0.910 dice katsayısı elde etmiş, beş veri setinde ise 0.878 dice ve 0.809 IoU ile önceki yöntemlere göre %14 ve %15 iyileşme sağlamışlardır.

Towards a computed-aided diagnosis system in colonoscopy: Automatic polyp segmentation using convolution neural networks [7]: Makalede kolonoskopi ve

kapsül endoskopisi için derin öğrenme tabanlı bir yöntem geliştirilmiştir. VGG ve ResNet'i FCN'ye dönüştürüp, "Shape from Shading" (gölgeden şekil çıkarma) ile derinlik bilgisini RGB'ye ekleyerek model performansını artırmışlardır. Model, ETIS-Larib'de %47.78, CVC-Colon'da %56.95 IoU ve %90 duyarlılık sağlamıştır.

ResUNet++: An Advanced Architecture for Medical Image Segmentation [8]: Makalede kullanılan ResUNet++ modeli, atlamalı bloklar ile gradyan sönmesini azaltır, ASPP ve dikkat mekanizmaları ile doğruluğu artırır. Kvasir-SEG'de %81.33, CVC-612'de ise %79.55 dice ile U-Net ve ResUNet'ten daha iyi performans göstermektedir.

3. KULLANILAN VERİ SETİ VE ALGORİTMALAR

Kolonoskopi görüntülerinden polip bölütlemesi için literatürdeki açık veri setleri seçilmiş ve derin öğrenme algoritmaları ile polip tespiti ve doğruluk oranı artırılmaya çalışılmıştır. Sınıflandırma veri setlerindeki polip içermeyen görüntüler boş maskelerle eşleştirilerek veri çeşitliliği artırılmıştır.

3.1. SUNUCU VE SQL

Veriler, daha az alan kullanarak güvenli saklama için base64 ile kodlanmış, polip maskeleri ise RLE algoritmasıyla sıkıştırılmıştır. Raspberry Pi 4 yalnızca veri depolama için kullanılmış, model eğitimi ve analiz Google Colab üzerinde yapılmıştır. SQLite veri tabanı, hızlı ve güvenli depolama amacıyla yapılandırılmıştır.

3.1.1. SQLITE VERİ İŞLEME

Veri setindeki kolonoskopi görüntüleri base64 ile şifrelenip, polip maskeleri RLE formatında sıkıştırılmıştır. Veriler, pandas tablosuna kaydedilip, SQLite ile veri tabanına dönüştürülerek sunucuya yüklenip kullanıma açılmıştır.

3.1.2. BASE64 ŞİFRELEME ALGORİTMASI


Base64, ikili veriyi metne dönüştüren bir kodlama yöntemidir. Veriler, 6 bitlik parçalara ayrılarak belirli karakterlerle temsil edilir, eksik bitler "=" ile tamamlanır. Örneğin, "Neuronauts" Base64 ile "TmVsZXJvbmF1dHM=" olarak kodlanır. Projemizde, kolonoskopi görüntülerini SQL veri tabanına aktarırken Base64 kullanılmıştır.

3.1.3. RLE SIKIŞTIRMA ALGORİTMASI

Polip bölütlemeye kullanılan ikili maskeler, her pikselin nesneye ait olup olmadığını belirtir. Bu maskelerdeki tekrarlamalar, Run-Length Encoding (RLE) algoritması ile verimli bir şekilde sıkıştırılabilir. Örneğin, bir boyutlu maske dizisi [0,0,0,1,1,1,0,0,1,1] RLE ile "3 0, 3 1, 2 0, 2 1" şeklinde ifade edilir; burada "3 0" üç ardışık 0'ı, "3 1" ise üç ardışık 1'i temsil eder. RLE, tekrar eden piksellerin yoğun olduğu maskelerde depolama maliyetini azaltırken, veri işleme hızını da artırır.

Sunucu Bilgileri	
Sunucu Cihazı	RaspberryPi 4 Model B Rev 1.5
İşletim Sistemi	Debian 12
İşlemci	ARM Cortex-A72
Bellek	32 GiB
Konum	İstanbul, Beykoz

Tablo 2 - Sunucu Bilgileri



Şekil 1 - RLE Akış Şeması

3.2. VERİ SETLERİMİZ

Elimizde bulunan polip bölütleme modeli üzerinde çalışırken, 12 farklı veri seti kullandık. Bu veri setlerinden 3'ü modelin performansını değerlendirmek amacıyla test sürecinde, geri kalan 8'i ise modelin eğitiminde kullanılmıştır. Toplamda 23.841 görüntüden oluşan veri setimiz, veri çeşitliliğini artırmak ve modelin genelleme yeteneğini iyileştirmek amacıyla veri artırma tekniklerinden biri olan elastik deformasyon yöntemi ile genişletilmiştir. Bu süreçte, 10.425 görüntü elastik deformasyon uygulanarak çoğaltılmış ve veri setimize eklenmiştir.

Veri artırma işlemi, modelin performansını olumlu etkileyerek daha başarılı sonuçlar elde edilmesine katkı sağlamıştır. Bu yöntemle, modelin performansı ve başarısı kapsamlı bir şekilde analiz edilmiştir.

3.3. VERİ ÖN İŞLEME

Veri setindeki görüntülerde bulanıklık, yansıma ve kabarcık gibi gürültüler ile histogram dengesizliği model performansını olumsuz etkilemektedir. Bu nedenle görüntülere kendi yazdığımız ön işleme fonksiyonu uygulanmıştır. Görüntüler için gri tonlamaya çevirme, boyutlandırma, Gaussian bulanıklaştırma, histogram eşitleme ve normalizasyon yapılmıştır. Maskeler için ise gri tonlamalı okuma, boyutlandırma ve normalizasyon işlemleri uygulanarak kaynak tüketimi azaltılmış, modelin performansı artırılmıştır.

3.3.1. SQLITE VERİ AKTARMA

Kolonoskopi görüntüleri ve polip maskelerinin bulunduğu bir veri tabanı, SQL'den pandas tablosuna aktarıldı. Görüntüler base64 formatında şifrelenmiş, maskeler ise RLE formatında sıkıştırılmış haldeydi. Görüntülerin base64 kodları çözülerek ham piksel verisine dönüştürüldü ve uygun format ile çözünürlük uyumluluğu sağlandı. Maskeler ise RLE formatından orijinal piksel matrisine çevrilerek çözünürlükleri görüntülerle eşleştirildi. Bu optimize edilmiş süreç, verilerin doğruluk ve performans öncelikli bir şekilde analiz ve ön işleme için hazırlanmasını sağladı.



Şekil 2 - Veri Setlerimiz

Veri Seti	Görüntü Sayısı	Kullanım Alanı
CVC-Clinic [9]	612	Eğitim
CVC-Colon [10]	380	Eğitim
Etis [11]	196	Eğitim
Kvasir [12]	1000	Eğitim
BKAI-IGH [13]	1200	Test
Binary Polyps [14]	1000	Test
WCE [15]	4500	Pasif
PolypDB [16]	3929	Test
Polyp-Seg [17]	1450	Eğitim
Polypgen2021 [18]	153	Pasif
PolypGen Negative [19]	4275	Pasif
PolypGen Positive [19]	3762	Pasif

Tablo 3 - Veri Setlerimiz



Şekil 3 - Ön İşlenmesiz Görüntü Örneği

```
import cv2
import base64

def sifrele(img):
    # Görüntüyü JPEG formatına kodla ve kodlanmış veriyi bir tamponda sakla.
    buffer = cv2.imencode('.jpg', img)

    # JPEG formatındaki tampon veriyi Base64 formatına çevir.
    img_base64 = base64.b64encode(buffer).decode('utf-8')

    return img_base64
```

Şekil 4 - Base64 Şifreleme Fonksiyonu

```
def RLE_to_maske(rle, yükseklik, genislik):
    gecisler = np.array([int(x) for x in rle.split()])

    # Başlangıç pozisyonlarını (3 tabanlı) ve uzunlukları ayır.
    baslangiclar = gecisler[::2]
    uzunluklar = gecisler[1::2]

    # Tüm pikselleri baslangiclar olarak ayarla.
    maske = np.zeros(yuksekklik * genislik, dtype=np.uint8)

    # Her baslangic pozisyonunda belirtilen uzunluk kadar pikseli 255 olarak ayarla.
    for baslangic, uzunluk in zip(baslangiclar, uzunluklar):
        baslangic = 1 + RLE, 1 tabanlı olduğundan 0 tabanlıya çevir.
        maske[baslangic:baslangic + uzunluk] = 255


    # Maskeyi belirtilen boyutlara göre yeniden şekillendir.
    maske = maske.reshape((yuksekklik, genislik))

    return maske
```

Şekil 5 - RLE'den Maskeye Çevirme Fonksiyonu

3.3.2. GAUSSIAN BULANIKLAŞTIRMA


Gaussian bulanıklaştırma [20], dijital görüntü işleme alanında, görüntüdeki yüksek frekanslı bileşenleri yumuşatarak, özellikle gürültüleri ve ince detayları azaltmak, aynı zamanda kenarları vurgulamak için sıklıkla kullanılan bir yöntemdir. Bu işlemde, her bir pikselin değeri, çevresindeki piksellerin ağırlıklı ortalaması alınarak hesaplanır. Bu ağırlıklar, bir Gaussian fonksiyonu (veya Gauss dağılımı) kullanılarak belirlenir, bu da her pikselin çevresindeki piksellere farklı derecelerde etki etmesini sağlar. Veri ön işleme aşamasında da Gaussian bulanıklaştırma yöntemi kullanılarak, görüntüdeki gürültü ve ince detaylar azaltılmış, böylece daha düzgün bir görüntü elde edilmiştir.



Şekil 6 - Gaussian Blur Çekirdek Gösterimi

3.3.3. HISTOGRAM EŞİTLEME

Histogram eşitleme, dijital görüntü işleme alanında kontrastı artırmak için yaygın olarak kullanılan bir yöntemdir. Bu teknik, görüntüdeki piksellerin parlaklık seviyelerini daha geniş bir aralığa yayarak, hem düşük hem de yüksek parlaklık seviyelerindeki detayların daha belirgin hale gelmesini sağlamaktadır. Piksellerin yoğunluğunu daha eşit bir dağılıma dönüştürmeyi hedefleyen bu işlem, özellikle düşük kontrastlı görüntülerin iyileştirilmesinde etkili bir şekilde kullanılmaktadır. Veri ön işleme aşamasında histogram eşitleme yöntemi kullanılarak, görüntünün kontrastı artırılmış ve detaylar daha belirgin hale getirilmiştir, böylece görüntü daha net ve ayrıntılı bir şekilde işlenmiştir.




Şekil 7 - Histogram Eşitlenmiş Görüntü


4. SONUÇLAR VE İNCELEME

Polip bölütlemesi araştırmalarında, farklı derin öğrenme modelleri ve mimariler test edilmiştir. Veri seti boyutunun model performansını etkilediği gözlemlenmiştir. U-Net ve U-Net++ modelleri, kısıtlı (2000) ve orta büyüklükteki (6000) veri setleriyle test edilmiştir. Kısıtlı veri seti, orta veri setine göre daha düşük performans göstermiştir. Dikkat mekanizmaları ve farklı encoder-decoder yapılarıyla daha yüksek doğruluk elde edilmeye çalışılmıştır. Sonuç olarak, gelişmiş mimariler ve teknikler gereklidir.

Bu süreç içerisinde model performansını en çok etkileyen faktörlerden birisinin öğrenme oranı olması nedeniyle iyi performans veren model farklı öğrenme oranları ile eğitilip ardından aynı test veri kümesi üzerinde test edilmiştir. 1e-3 öğrenme oranı ile test ortalama IoU olarak 0.7463, 1e-4 öğrenme oranı ile 0.7655, 1e-5 öğrenme oranı ile 0.7499 alınmıştır. Bu sonuçlar göz önünde bulundurularak 1e-4 öğrenme oranının kullanılmasına karar verilmiştir.




Şekil 8 - Eğitim Kümesi Boyutuna Göre Test Performans Grafiği



Şekil 9 - Öğrenme Oranına Göre Test Performans Grafiği

4.1. ATTENTION U-NET / GELİŞMİŞ ATTENTION U-NET


Attention U-Net [21], görüntüdeki önemli alanlara odaklanarak bölütleme doğruluğunu artıran bir modeldir. Dikkat mekanizmaları, modelin önemli bölgelere odaklanmasını sağlamaktadır. Gelişmiş Attention U-Net, klasik modele göre kanal sayısını esnek şekilde değiştirerek daha iyi sonuçlar elde etmiştir. Bu mekanizma, çözünürlük kaybını en aza indirmektedir. Polyp DB veri kümesinde test edilen model, 0.7385 ortalama IoU skoru elde etmiş, ancak klinik uygulamalarda daha yüksek doğruluk gereksinimlerini karşılamadığı için yetersiz değerlendirilmiştir.



Şekil 10 - Attention U-Net Mimarisi

4.2. U-NET++

U-Net++ [22], klasik U-Net modeline ek olarak, derin ve karmaşık bir yapı sunmaktadır. Bu model, özellikle daha iyi özelliği birleştirme ve bağlamı anlamada faydalıdır. U-Net++'daki bir yenilik, daha fazla ve derinlemesine atlama bağlantıları kullanılarak, özelliklerin daha iyi entegrasyonunu sağlar. Bu mimari, polip bölütlemesinde ayrıntılı çıkarım yaparak bölütleme maskesinin doğruluğunu artırır.




Şekil 11 - U-Net++ Mimarisi

U-Net++ modeli, Polyp DB veri kümesinde test edilerek polip segmentasyon başarısını değerlendiren bir derin öğrenme modelidir. Bu model, Attention U-Net'e kıyasla daha iyi bir performans sergileyerek, ortalama IoU skorunu 0.8655 olarak elde etmiştir. Bu skor, mevcut modeller arasında en başarılı sonuç olarak kaydedilmiştir.

4.3. DEEPLABV3+

DeepLabV3+ [23] genişlemeli konvolüsyonlar (Atrous convolutions) kullanarak daha geniş bağlamsal bilgi edinen ve özellikle medikal görüntü bölütleme alanında yüksek doğruluk sağlayan gelişmiş bir modeldir. Bu yapısı, küçük ve karmaşık sınırları olan nesnelerin daha hassas tespit edilmesine olanak tanımaktadır.




Şekil 12 - DeepLabV3+ Mimarisi

Deneyisel çalışmalar sonucunda, DeepLabV3+ modelinin 0.7844 ortalama IoU (Intersection over Union) skoru elde ettiği belirlenmiştir. Bu metrik, modelin nesne sınırlarını doğru bir şekilde ayırt edebildiğini göstermektedir. Sonuçlar, DeepLabV3+'ün medikal görüntü analizi ve bölütleme süreçlerinde etkin bir model olduğunu ortaya koymaktadır.

4.4. PVT-CASCADE


Literatür taramasında, PVT-Cascade (Pyramid Vision Transformer Cascade) modeli [24] keşfedilmiştir. Medikal bölütleme için geliştirilen bu model, piramidal yapıyla çok ölçekli bilgi elde eder. Farklı ölçeklerden gelen bilgileri kademeli entegre ederek poliplerin çeşitli boyut ve yapılarına etkili sonuçlar sağlamaktadır. Ancak yüksek kaynak tüketimi nedeniyle daha verimli alternatifler arandığı için PVT-Cascade kullanılmamıştır. DeepLabV3+, Polyp DB veri kümesinde 0.6051 IoU ile orta düzeyde performans sergilemiştir. Ancak, küçük yapıları segment etmede U-Net++ gibi modeller daha başarılı sonuçlar vermektedir, bu da modelin performansının artırılması gerektiğini göstermektedir.



Şekil 13 - PVT-Cascade Mimarisi

4.5. PATCH REFINEMENT NETWORK

Model sonuçlarının yetersiz görülmesi üzerine, Kvasir-SEG üzerinde test edilen modeller incelenmiş ve en yüksek mIoU skorunu alan SSFormer-S + PRN modeli [25] denenmiştir. SSFormer-S+PRN, Vision Transformer tabanlı bir yaklaşım kullanarak güçlü segmentasyon performansı sergilemektedir. Model, çok ölçekli bilgi işleme yeteneğiyle farklı boyut ve yapıya sahip nesneleri tanımlamaktadır. SSFormer özellik çıkarımı yaparken, PRN segmentasyon maskelerini aşamalı olarak iyileştirir. Polip gibi değişken şekil ve boyutlardaki nesnelerin tespitinde başarılıdır. Ancak, yüksek kaynak tüketimi ve verimlilik ihtiyacı nedeniyle daha hafif modellere yönelme gerekliliği doğmuştur.




Şekil 14 - Patch Refinement Network Gösterimi


4.6. SONUÇLAR

Polip segmentasyonu konusunda gerçekleştirilen bu çalışmada, farklı derin öğrenme mimarileri belirtilen veri setleri üzerinde eğitilmiş ve sonrasında performans değerlendirmesi için PolypDB, Binary Polyps ve BKAI-IGH veri setleri kullanılmıştır. Bu test sürecinde, model performanslarını değerlendirmek amacıyla doğrulama ortalama IoU metriği tercih edilmiştir.

Tablo 4'te, testlerde kullanılan öğrenme oranları, optimizatörler, kayıp fonksiyonları ve diğer önemli hiperparametrelere ilişkin ayrıntılı bilgiler sunulmaktadır. Yapılan analizler sonucunda, U-Net++ model mimarisinin diğer test edilen derin öğrenme modellerine kıyasla daha üstün bir segmentasyon performansı sergilediği tespit edilmiştir. U-Net++'ın PolypDB veri kümesi üzerinde gerçekleştirilen test süreci, modelin segmentasyon başarısını ayrıntılı bir şekilde inceleme ve modelin etkinliğini



Şekil 15 - Doğrulama Ortalama IoU Grafiği



Şekil 16 - Doğrulama Doğruluğu Grafiği

değerlendirme olanağı sağlamıştır. Bu süreçte, U-Net++ modeli 0.8907 ortalama IoU skoruna ulaşmış ve segmentasyon görevinde yüksek bir performans göstermiştir.

Bu sonuçlar, U-Net++'ın polip segmentasyonu görevinde daha yüksek bir doğruluk seviyesi sunduğunu ve poliplerin doğru bir şekilde tespit edilip bölütlenmesinde kayda değer bir başarı elde ettiğini göstermektedir. U-Net++ modelinin başarısı, kullanılan mimarinin karmaşıklığı ve çok katmanlı yapısının, polip segmentasyonu gibi hassas bir görevde detaylı ve kesin sonuçlar elde edilmesine olanak sağladığını ortaya koymaktadır. Bu durum, özellikle klinik uygulamalarda modelin kullanım potansiyelini artırmakta ve gelecekteki çalışmalar için referans bir yapı teşkil etmektedir.


Model \ Veri Seti	U-Net++	DeepLabV3+	Gelişmiş Attention U-Net	Attention U-Net Adam Optimizatör	Attention U-Net SGD Optimizatör	Attention U-Net AdamW Optimizatör
CVC-Clinic	0.9101	0.8770	0.9384	0.8758	0.4569	0.7759
CVC-Colon	0.9052	0.7736	0.8350	0.8613	0.4583	0.8424
Etis	0.8359	0.8549	0.8235	0.8438	0.4773	0.7530
Hyper	0.8901	0.8377	0.8612	0.8912	0.4236	0.8609
Kvasir	0.8900	0.8376	0.8611	0.8511	0.4236	0.7609
Polyp-Gen Negative	0.4956	0.4977	0.4971	0.4936	0.4999	0.4961
Polyp-Gen Positive	0.6775	0.5654	0.6572	0.6256	0.4580	0.6629
Polyp-Gen 2021	0.7555	0.6015	0.7218	0.7000	0.4517	0.7322
Neopolyp	0.4707	0.4858	0.4754	0.4737	0.5000	0.4756
Binary	0.4909	0.4957	0.4903	0.4840	0.5000	0.4883
WCE	0.4888	0.4974	0.4901	0.4880	0.5000	0.4876
Polyp-DB	0.8655	0.8051	0.7385	0.8076	0.4580	0.7328
Polyp-SEG	0.8677	0.8552	0.8781	0.8506	0.4370	0.7706
Hepsi	0.8907	0.7844	0.8185	0.8075	0.4647	0.8154

Tablo 4 - Modellerin Veri Setlerindeki Ortalama IoU Değerleri

5. ÖZGÜNLÜK

5.1. BİLATERAL FİLTRELEME

Bilateral filtre [26], görüntüyü pürüzsüzleştirirken kenarları koruyan bir ağırlıklı ortalama filtresidir. Piksellerin değeri, hem konumlarına hem de renk farklarına göre hesaplanmaktadır, bu sayede benzer renkler etkilenirken kenarlar korunmaktadır. Gürültü giderme ve görüntü düzleştirme için etkili olan bu filtre, Şekil 17 - Bilateral Filtrenilmiş Görüntü modelimizin performansını artırmak amacıyla kullanılmıştır. Yapılan deneyler sonucunda, filtreleme yöntemi sayesinde hem gürültünün azaltıldığı hem de görüntü özelliklerinin daha belirgin hale geldiği gözlemlenmiştir.



5.2. ELASTİK DEFORMASYON

Elastik deformasyon [27], görüntülerde doğrusal olmayan şekil bozulmaları oluşturarak veri çeşitliliğini artıran bir teknik olarak kullanılmıştır. Her piksel rastgele kaydırılarak pürüzsüz deformasyonlar elde edilmiştir. Ancak, diğer veri çoğaltma yöntemlerinin model performansına daha olumlu katkı sağladığı gözlemlenmiştir. Elastik deformasyon uygulanmayan model, test veri kümesinde 0.5998 IoU alırken, elastik deformasyonlu modelin IoU skoru 0.5835 olarak ölçülmüştür. Farklı modellerde bu performans farkının arttığı ve elastik deformasyonun görüntülerdeki detayları bozduğu belirlenmiştir. Bu nedenle, yöntemin devre dışı bırakılmasına karar verilmiştir.



Şekil 18 - Elastik Deformasyon Gösterimi

5.3. KOMBİNASYON FONKSİYONU

Denemelerde kullanılan veri setleri süreç içerisinde değişmiştir. Süreci hızlandırmak amacıyla veri seti hazırlama, otomasyona geçirilmiştir. Tablo 3'te belirtilen veri setlerini içeren bir sözlük oluşturulmuştur. Fonksiyona sözlüğün içindeki ikili değerler değiştirilerek veri setlerini değiştirme özelliği eklenmiştir.

```
def kombinasyon(path,comb):
    images=[]
    masks=[]
    folders=[key for key,value in comb.items() if value == 1]
    for subfolder in tqdm(os.listdir(path)):
        if subfolder not in folders:
            continue
        subfolder_path = os.path.join(path,subfolder)
        for image in tqdm(os.listdir(os.path.join(subfolder_path,'images'))):
            image_path = os.path.join(subfolder_path,'images',image)
            images.append(preprocess(image_path))
        for mask in tqdm(os.listdir(os.path.join(subfolder_path,'masks'))):
            mask_path = os.path.join(subfolder_path,'masks',mask)
            masks.append(preprocess(mask_path))
    return np.array(images), np.array(masks)

comb = {
    'colonic':0,
    'cecal':0,
    'ileal':0,
    'hyper':0,
    'normal':0,
    'polypoid-negative':1,
    'polypoid-positive':1,
    'polypoid':0,
    'sessile':0,
    'sessile':0
}
```


Şekil 19 - Kombinasyon Fonksiyonu

5.4. GÖRÜNTÜ VERİ ÜRETİCİSİ

Görüntü Veri Üreticisi, veri artırma yaparak modelin genelleme yeteneğini artırır ve aşırı öğrenmeyi önler. Döndürme, çevirme, ölçekleme gibi dönüşümlerle mevcut görüntülerden çeşitlendirilmiş veriler üreterek modelin farklı görsellere uyumunu güçlendirir. Görüntü Veri Üreticisi kullanımının diğer tekniklere göre modelin genel başarısını, genelleme yeteneğini artırdığı görülmüştür ve kullanılması tercih edilmiştir.

5.5. CAWR ALGORİTMASI

Cosine Annealing Warm Restarts (CAWR) [28], öğrenme oranını kosinüs fonksiyonuna bağlı olarak kademeli azaltan ve belirli aralıklarla yeniden başlatan bir optimizasyon yöntemidir. Bu sayede model, farklı çözüm alanlarını keşfederek yerel minimumlarda takılma riskini azaltır.



Şekil 20 - CAWR Öğrenme Oranı Grafiği

CAWR, başlangıç (η_{max}) ve minimum (η_{min}) öğrenme oranları, ilk döngü uzunluğu (T_0) ve döngü genişleme faktörü (T_{mult}) gibi parametreler içerir. Öğrenme oranı, her döngüde kosinüs fonksiyonuna göre azalır ve döngü sonunda

$$\eta_t = \eta_{min} + \frac{1}{2}(\eta_{max} - \eta_{min}) \left(1 + \cos \left(\frac{T_{cur}}{T_i} \pi \right) \right)$$

Şekil 21 - CAWR Matematiksel Gösterimi sıfırlanarak modelin daha geniş bir çözüm uzayını taramasını sağlar. Eğitim sürecinde CAWR kullanılarak modelin farklı parametre uzaylarını keşfetmesi sağlanmış, yakınsama hızlanmış ve doğruluk oranı artırılmıştır.

6. REFERANSLAR

[1] Ramalingam, K., & Jamal, D. N. (2025). Enhancing colonoscopy image quality through multi-step computational pre-processing techniques. Informatics, 48(23), 6498. <https://doi.org/10.31449/inf.v48i23.6498>

- [2] Bernal, J., Sánchez, J., & Vilariño, F. (2013). Impact of image preprocessing methods on polyp localization in colonoscopy frames. Proceedings of the 35th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC), 2013, 5234-5237. <https://doi.org/10.1109/embc.2013.6611256>
- [3] Castro, E., Cardoso, J. S., & Pereira, J. C. (2018). Elastic deformations for data augmentation in breast cancer mass detection. Proceedings of the 2018 IEEE International Conference on Biomedical Health Informatics (BHI), 2018, 140-143. <https://doi.org/10.1109/BHI.2018.8333411>
- [4] Akbari, M., Mohrekesh, M., Nasr-Esfahani, E., Soroushmehr, S. M. R., Karimi, N., Samavi, S., & Najarian, K. (2018). Polyp segmentation in colonoscopy images using fully convolutional network. arXiv. <https://doi.org/10.48550/arXiv.1802.00368>
- [5] Jha, D., Ali, S., Nikhil, Tomar, K., Johansen, H. D., Johansen, D., Rittscher, J., Riegler, M. A., & Halvorsen, P. (2021). Real-time polyp detection, localization and segmentation in colonoscopy using deep learning. IEEE Access, 9, 138855-138866. <https://doi.org/10.1109/ACCESS.2021.3063716>
- [6] Yeung, M., Sala, E., Schönlieb, C.-B., & Rundo, L. (2021). Focus U-Net: A novel dual attention-gated CNN for polyp segmentation during colonoscopy. arXiv. <https://doi.org/10.48550/arXiv.2105.07467>
- [7] Brandao, P., Zisimopoulos, O., Mazomenos, E., Ciuti, G., Bernal, J., Visentini-Scarzanella, M., Menciassi, A., Dario, P., Koulaouzidis, A., Arezzo, A., Hawkes, D. J., & Stoyanov, D. (2021). Towards a computed-aided diagnosis system in colonoscopy: Automatic polyp segmentation using convolution neural networks. arXiv. <https://doi.org/10.48550/arXiv.2101.06040>
- [8] Jha, D., Smedsrud, P. H., Riegler, M. A., Johansen, D., de Lange, T., Halvorsen, P., & Johansen, H. D. (2019). ResUNet++: An advanced architecture for medical image segmentation. arXiv. <https://doi.org/10.48550/arXiv.1911.07067>
- [9] Bernal, J., Sánchez, F. J., Fernández-Esparrach, G., Gil, D., Rodríguez, C., & Vilariño, F. (2015). WM-DOVA maps for accurate polyp highlighting in colonoscopy: Validation vs. saliency maps from physicians. Computerized Medical Imaging and Graphics, 43, 99-111 .
- [10] Jorge Bernal, F. Javier Sanchez, & Fernando Vilariño. “Towards Automatic Polyp Detection with a Polyp Appearance Model”. *Pattern Recognition*, 45(9), 3166–3182.
- [11] Silva J.S., Histace A., Romain O., Dray X., Granado B. Toward embedded detection of polyps in WCE images for early diagnosis of colorectal cancer. *Int. J. Comput. Assist. Radiol. Surg.* 2014;9:283–293. doi: 10.1007/s11548-013-0926-3.
- [12] Jha, D., Smedsrud, P. H., Riegler, M. A., Halvorsen, P., de Lange, T., Johansen, D., & Johansen, H. D. (2020). Kvasir-seg: A segmented polyp dataset. *International Conference on Multimedia Modeling*, 451–462. Springer.
- [13] Dinh Sang. BKAI-IGH NeoPolyp. <https://kaggle.com/competitions/bkai-igh-neopolyp>, 2021. Kaggle.
- [14] Mdsahilurrahman71. *Binary polyps classification* [Data set]. Kaggle. <https://www.kaggle.com/datasets/mdsahilurrahman71/binary-polyps-classification>
- [15] Silva, J., Histace, A., Romain, O., Dray, X., & Granado, B. (2014). Toward embedded detection of polyps in WCE images for early diagnosis of colorectal cancer.

<https://doi.org/10.1007/s11548-013-0926-3>

[16] Jha, D., Tomar, N. K., Sharma, V., Trinh, Q.-H., Biswas, K., Pan, H., ... Bagci, U. (2025). PolypDB: A Curated Multi-Center Dataset for Development of AI Algorithms in Colonoscopy. *arXiv [Cs.CV]*. Retrieved from <http://arxiv.org/abs/2409.00045>

[17] pagethpageth. *PolypSegmentDataset* [Data set]. Kaggle.

<https://www.kaggle.com/datasets/pagethpageth/polypsegmentdataset>

[18] kokoroou. (2021). *PolypGen2021* [Data set]. Kaggle.

<https://www.kaggle.com/datasets/kokoroou/polypgen2021>

[19] Ali, S., Jha, D., Ghatwary, N., Realdon, S., Cannizzaro, R., Salem, O. E., ...

East, J. E. (2023). A multi-centre polyp detection and segmentation dataset for generalisability assessment. *Scientific Data*, 10(1). doi:10.1038/s41597-023-01981-y

[20] Necipsoy, M. E., & Ergüzen, A. (2024). Facial Tracking, Recognition, And Utilizing Gaussian Blur In Face Recognition Sytems Via The OpenCv Library.

International Scientific and Vocational Studies Journal, 8(2), 103-122.

<https://doi.org/10.47897/bilmes.1501078>

[21] Oktay, O., Schlemper, J., Le Folgoc, L., Lee, M., Heinrich, M., Misawa, K., Mori, K., McDonagh, S., Hammerla, N. Y., Kainz, B., Glocker, B., & Rueckert, D. (2018).

Attention U-Net: Learning where to look for the pancreas.

<https://doi.org/10.48550/arXiv.1804.03999>

[22] Zhou, Z., Siddiquee, M. M. R., Tajbakhsh, N., & Liang, J. (2018). UNet++: A nested U-Net architecture for medical image segmentation.

<https://doi.org/10.48550/arXiv.1807.10165>

[23] Chen, L.-C., Zhu, Y., Papandreou, G., Schroff, F., & Adam, H. (2018). Encoder-decoder with atrous separable convolution for semantic image segmentation.

<https://doi.org/10.48550/arXiv.1802.02611>

[24] M. M. Rahman and R. Marculescu, "Medical Image Segmentation via Cascaded Attention Decoding," *2023 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, Waikoloa, HI, USA, 2023, pp. 6211-6220, doi: 10.1109/WACV56688.2023.00616.

[25] Savinay Nagendra, Chaopeng Shen & Daniel Kifer (2023). PatchRefineNet: Improving Binary Segmentation by Incorporating Signals from Optimal Patch-wise

Binarization <https://doi.org/10.48550/arXiv.2211.06560>

[26] Akshay Gadde, Sunil K Narang & Antonio Ortega (2013). Bilateral Filter: Graph Spectral Interpretation and Extensions, 1-11.

<https://doi.org/10.48550/arXiv.1303.2685>

[27] Sebastien C. Wong, Adam Gatt, Victor Stamatescu & Mark D. McDonnell (2016). Understanding data augmentation for classification: when to warp?, 2.

<https://doi.org/10.48550/arXiv.1609.08764>

[28] Gotmare, A., Keskar, N. S., Xiong, C., & Socher, R. (2018). A Closer Look at Deep Learning Heuristics: Learning rate restarts, Warmup and Distillation. *arXiv [Cs.LG]*.

<http://arxiv.org/abs/1810.13243>